







Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Primer contacto con los datos

2013,9,30,2009,2000,9,2238,2300,-22,VX,415,N844VA,JFK,LAX,303,2475,20,0,2013-10-01T00:00:00Z
2013,9,30,2009,2009,0,2126,2129,-3,UA,1049,N77258,EWR,BOS,38,200,20,9,2013-10-01T00:00:00Z
2013,9,30,2010,2012,-2,2143,2150,-7,EV,4106,N12921,EWR,GSO,64,445,20,12,2013-10-01T00:00:00Z
2013,9,30,2010,2016,-6,2119,2128,-9,EV,4312,N13969,EWR,DCA,35,199,20,16,2013-10-01T00:00:00Z
2013,9,30,2010,2015,-5,2100,2125,-25,B6,418,N249JB,JFK,BOS,35,187,20,15,2013-10-01T00:00:00Z
2013,9,30,2012,2015,-3,2117,2144,-27,B6,702,N339JB,JFK,BUF,51,301,20,15,2013-10-01T00:00:00Z
2013,9,30,2013,2000,13,2133,2120,13,US,2195,N747UW,LGA,DCA,41,214,20,0,2013-10-01T00:00:00Z
2013,9,30,2015,2030,-15,2221,2251,-30,EV,5209,N741EV,LGA,CHS,84,641,20,30,2013-10-01T00:00:00Z
2013,9,30,2015,2015,0,2244,2307,-23,UA,1545,N17730,EWR,IAH,174,1400,20,15,2013-10-01T00:00:00Z
2013,9,30,2016,2022,-6,2215,2246,-31,B6,135,N607JB,JFK,PHX,263,2153,20,22,2013-10-01T00:00:00Z
2013,9,30,2017,2022,-5,2132,2155,-23,B6,105,N298JB,JFK,ORD,112,740,20,22,2013-10-01T00:00:00Z
2013,9,30,2017,2017,0,2253,2320,-27,UA,771,N510UA,JFK,LAX,304,2475,20,17,2013-10-01T00:00:00Z
2013,9,30,2019,2023,-4,2225,2240,-15,EV,4085,N14188,EWR,OMA,149,1134,20,23,2013-10-01T00:00:00Z
2013,9,30,2021,2022,-1,2144,2200,-16,UA,1464,N76503,EWR,CLE,54,404,20,22,2013-10-01T00:00:00Z
2013,9,30,2022,2025,-3,2127,2140,-13,AA,2314,N3CUAA,JFK,BOS,37,187,20,25,2013-10-01T00:00:00Z
2013,9,30,2023,2025,-2,2315,2350,-35,B6,915,N712JB,JFK,SFO,327,2586,20,25,2013-10-01T00:00:00Z
2013,9,30,2026,2028,-2,2317,2340,-23,UA,1680,N31412,EWR,MIA,141,1085,20,28,2013-10-01T00:00:00Z
2013,9,30,2027,2034,-7,2129,2209,-40,9E,4127,N8790A,JFK,IAD,41,228,20,34,2013-10-01T00:00:00Z
2013,9,30,2028,1910,78,2255,2215,40,AA,21,N338AA,JFK,LAX,294,2475,19,10,2013-09-30T23:00:00Z
2013,9,30,2030,2045,-15,2141,2153,-12,B6,2680,N266JB,EWR,BOS,38,200,20,45,2013-10-01T00:00:00Z
2013,9,30,2030,2035,-5,2324,2340,-16,UA,374,N484UA,EWR,FLL,141,1065,20,35,2013-10-01T00:00:00Z
2013,9,30,2031,2040,-9,2228,2300,-32,9E,4033,N8924B,LGA,TYS,86,647,20,40,2013-10-01T00:00:00Z
2013,9,30,2032,1945,47,2115,2106,9,9E,3864,N602XJ,JFK,PHL,24,94,19,45,2013-09-30T23:00:00Z
2013,9,30,2032,2045,-13,2147,2225,-38,AA,371,N434AA,LGA,ORD,105,733,20,45,2013-10-01T00:00:00Z
2013,9,30,2033,2030,3,2143,2150,-7,WN,2520,N286WN,EWR,MDW,97,711,20,30,2013-10-01T00:00:00Z
2013,9,30,2034,2040,-6,2227,2248,-21,EV,4536,N25134,EWR,CVG,80,569,20,40,2013-10-01T00:00:00Z
2013,9,30,2034,2030,4,2204,2201,3,FL,354,N894AT,LGA,CAK,58,397,20,30,2013-10-01T00:00:00Z

Archivos en la computadora

El formato CSV




Licenciatura en
Ciencia de Datos
ECYT_UNSAM

CSV, su nuevo mejor amigo

- Comma-Separated-Values
- Son archivos de texto, donde las columnas están separadas por una coma
- Formato estándar para transmitir datos estructurados

```
1 long,lat,nro_registro,comuna,calle_nombre,calle_altura,calle_chapa,  
  nombre_cientifico,ancho_acera,estado_planter,ubicacion_planter,  
  nivel_planter,diametro_altura_pecho,altura_arbol  
2 -58.52246854385779,-34.635242540536105,248212,9,Alvarez Jonte Av.,6500,6509,  
  Lagerstroemia,4.4,Ocupada,Regular,Bajo nivel,4,2  
3 -58.522629550526105,-34.6354294300277,248235,9,Alvarez Jonte Av.,6500,6563,  
  Melia,4.4,Ocupada,Regular,A nivel,70,10  
4 -58.522684484956706,-34.635493195266,248260,9,Alvarez Jonte Av.,6500,6567,Melia  
  4.4,Ocupada,Regular,A nivel,73,10  
5 -58.5228272952872,-34.635658962044204,248278,9,Alvarez Jonte Av.,6500,6591,  
  Melia,4.4,Ocupada,Regular,A nivel,57,11  
6 -58.5221122386389,-34.634885150978604,248675,9,Alvarez Jonte Av.,6400,6481,  
  Melia,4,Ocupada,Regular,A nivel,58,9  
7 -58.522164769565705,-34.6349430221208,248701,9,Alvarez Jonte Av.,6400,6485,  
  Melia,4,Ocupada,Regular,A nivel,57,9  
8 -58.5218837652316,-34.634633450096196,248619,9,Alvarez Jonte Av.,6400,6457,  
  Lagerstroemia,4,Ocupada,Regular,Elevada,30,8  
9 -58.521941356652896,-34.634696896668004,248632,9,Alvarez Jonte Av.,6400,6465,  
  Melia,4,Ocupada,Regular,A nivel,77,8  
10 -58.522055938054294,-34.634823126844694,248655,9,Alvarez Jonte Av.,6400,6473,  
  Ficus,4,Ocupada,Regular,A nivel,35,6
```

Encabezados



Licenciatura en
Ciencia de Datos
ECYT_UNSAM



Encabezado
(Header)

Readme

Preguntar

	year	month	day	dep_time	sched_dep_time	dep_delay	arr_time	sched_arr_time	arr_delay	carrier	flight	tailnum	origin	dest	air_time	distance	hour	minute	time_hour
0	2013	1	1	517.0	515	2.0	830.0	819	11.0	UA	1545	N14228	EWR	IAH	227.0	1400	5	15	2013-01-01T10:00:00Z
1	2013	1	1	533.0	529	4.0	850.0	830	20.0	UA	1714	N24211	LGA	IAH	227.0	1416	5	29	2013-01-01T10:00:00Z
2	2013	1	1	542.0	540	2.0	923.0	850	33.0	AA	1141	N619AA	JFK	MIA	160.0	1089	5	40	2013-01-01T10:00:00Z
3	2013	1	1	544.0	545	-1.0	1004.0	1022	-18.0	B6	725	N804JB	JFK	BQN	183.0	1576	5	45	2013-01-01T10:00:00Z
4	2013	1	1	554.0	600	-6.0	812.0	837	-25.0	DL	461	N668DN	LGA	ATL	116.0	762	6	0	2013-01-01T11:00:00Z
5	2013	1	1	554.0	558	-4.0	740.0	728	12.0	UA	1696	N39463	EWR	ORD	150.0	719	5	58	2013-01-01T10:00:00Z
6	2013	1	1	555.0	600	-5.0	913.0	854	19.0	B6	507	N516JB	EWR	FLL	158.0	1065	6	0	2013-01-01T11:00:00Z
7	2013	1	1	557.0	600	-3.0	709.0	723	-14.0	EV	5708	N829AS	LGA	IAD	53.0	229	6	0	2013-01-01T11:00:00Z
8	2013	1	1	557.0	600	-3.0	838.0	846	-8.0	B6	79	N593JB	JFK	MCO	140.0	944	6	0	2013-01-01T11:00:00Z
9	2013	1	1	558.0	600	-2.0	753.0	745	8.0	AA	301	N3ALAA	LGA	ORD	138.0	733	6	0	2013-01-01T11:00:00Z
10	2013	1	1	558.0	600	-2.0	849.0	851	-2.0	B6	49	N793JB	JFK	PBI	149.0	1028	6	0	2013-01-01T11:00:00Z
11	2013	1	1	558.0	600	-2.0	853.0	856	-3.0	B6	71	N657JB	JFK	TPA	158.0	1005	6	0	2013-01-01T11:00:00Z
12	2013	1	1	558.0	600	-2.0	924.0	917	7.0	UA	194	N29129	JFK	LAX	345.0	2475	6	0	2013-01-01T11:00:00Z
13	2013	1	1	558.0	600	-2.0	923.0	937	-14.0	UA	1124	N53441	EWR	SFO	361.0	2565	6	0	2013-01-01T11:00:00Z
14	2013	1	1	559.0	600	-1.0	941.0	910	31.0	AA	707	N3DUAA	LGA	DFW	257.0	1389	6	0	2013-01-01T11:00:00Z
15	2013	1	1	559.0	559	0.0	702.0	706	-4.0	B6	1806	N708JB	JFK	BOS	44.0	187	5	59	2013-01-01T10:00:00Z
16	2013	1	1	559.0	600	-1.0	854.0	902	-8.0	UA	1187	N76515	EWR	LAS	337.0	2227	6	0	2013-01-01T11:00:00Z
17	2013	1	1	600.0	600	0.0	851.0	858	-7.0	B6	371	N595JB	LGA	FLL	152.0	1076	6	0	2013-01-01T11:00:00Z
18	2013	1	1	600.0	600	0.0	837.0	825	12.0	MQ	4650	N542MQ	LGA	ATL	134.0	762	6	0	2013-01-01T11:00:00Z
19	2013	1	1	601.0	600	1.0	844.0	850	-6.0	B6	343	N644JB	EWR	PBI	147.0	1023	6	0	2013-01-01T11:00:00Z
20	2013	1	1	602.0	610	-8.0	812.0	820	-8.0	DL	1919	N971DL	LGA	MSP	170.0	1020	6	10	2013-01-01T11:00:00Z
21	2013	1	1	602.0	605	-3.0	821.0	805	16.0	MQ	4401	N730MQ	LGA	DTW	105.0	502	6	5	2013-01-01T11:00:00Z
22	2013	1	1	606.0	610	-4.0	858.0	910	-12.0	AA	1895	N633AA	EWR	MIA	152.0	1085	6	10	2013-01-01T11:00:00Z
23	2013	1	1	606.0	610	-4.0	837.0	845	-8.0	DL	1743	N3739P	JFK	ATL	128.0	760	6	10	2013-01-01T11:00:00Z
24	2013	1	1	607.0	607	0.0	858.0	915	-17.0	UA	1077	N53442	EWR	MIA	157.0	1085	6	7	2013-01-01T11:00:00Z
25	2013	1	1	608.0	600	8.0	807.0	735	32.0	MQ	3768	N9EAMQ	EWR	ORD	139.0	719	6	0	2013-01-01T11:00:00Z
26	2013	1	1	611.0	600	11.0	945.0	931	14.0	UA	303	N532UA	JFK	SFO	366.0	2586	6	0	2013-01-01T11:00:00Z
27	2013	1	1	613.0	610	3.0	925.0	921	4.0	B6	135	N635JB	JFK	RSW	175.0	1074	6	10	2013-01-01T11:00:00Z
28	2013	1	1	615.0	615	0.0	1039.0	1100	-21.0	B6	709	N794JB	JFK	SJU	182.0	1598	6	15	2013-01-01T11:00:00Z
29	2013	1	1	615.0	615	0.0	833.0	842	-9.0	DL	575	N326NB	EWR	ATL	120.0	746	6	15	2013-01-01T11:00:00Z

Algunas definiciones



Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Unidades: Objetos principales de estudio: *de qué trata el dataset*.

Ej.: en **nycflights13** son los vuelos de los aeropuertos de la ciudad de Nueva York en el año 2013. También llamadas *instancias, ejemplos, entidades, casos, sujetos, registros*, etc.

Variables: Propiedades, cualidades o atributos medibles de las unidades.

Ej.: aerolínea, fecha, atraso en la salida, etc.



Valores: Resultados concretos de las variables para una unidad, son los **estados** de las variables una vez medida.

Ej.: atraso en la salida = 12, fecha= 21/12/2013, etc.

Observaciones: Es el conjunto de **valores** de **todas** las variables **para una misma unidad** medidas en condiciones similares (en general, hechas en el mismo tiempo y para el mismo objeto).

Ej.: Todos los datos de un vuelo específico (fecha, atraso, aerolínea, aeropuerto de salida, etc.)

Algunas definiciones



Licenciatura en
Ciencia de Datos
ECYT_UNSAM


Toda esta información se puede presentar de muchas maneras, nos va a interesar una en particular, lo vamos a llamar *datos ordenados*, *tidy - data* o simplemente ***tidy***.

Un dataset está *ordenado* **si y solo si** cumple **todas** estas reglas a la vez:

- Cada variable debe tener su propia columna.
- Cada observación en su propia fila.
- Cada valor en su propia celda.

(Estas reglas están interrelacionadas, es imposible cumplir solo dos de las tres)

Un ejemplo ordenado (*tidy*)



Licenciatura en
Ciencia de Datos
ECYT_UNSAM



Variables

Observación /
Data point

	year	month	day	dep_time	sched_dep_time	dep_delay	arr_time	sched_arr_time	arr_delay	carrier	flight	tailnum	origin	dest	air_time	distance	hour	minute	time_hour
0	2013	1	1	517.0	515	2.0	830.0	819	11.0	UA	1545	N14228	EWR	IAH	227.0	1400	5	15	2013-01-01T10:00:00Z
1	2013	1	1	533.0	529	4.0	850.0	830	20.0	UA	1714	N24211	LGA	IAH	227.0	1416	5	29	2013-01-01T10:00:00Z
2	2013	1	1	542.0	540	2.0	923.0	850	33.0	AA	1141	N619AA	JFK	MIA	160.0	1089	5	40	2013-01-01T10:00:00Z
3	2013	1	1	544.0	545	-1.0	1004.0	1022	-18.0	B6	725	N804JB	JFK	BQN	183.0	1576	5	45	2013-01-01T10:00:00Z
4	2013	1	1	554.0	600	-6.0	812.0	837	-25.0	DL	461	N668DN	LGA	ATL	116.0	762	6	0	2013-01-01T11:00:00Z
5	2013	1	1	554.0	558	-4.0	740.0	728	12.0	UA	1696	N39463	EWR	ORD	150.0	719	5	58	2013-01-01T10:00:00Z
6	2013	1	1	555.0	600	-5.0	913.0	854	19.0	B6	507	N516JB	EWR	FLL	158.0	1065	6	0	2013-01-01T11:00:00Z
7	2013	1	1	557.0	600	-3.0	709.0	723	-14.0	EV	5708	N829AS	LGA	IAD	53.0	229	6	0	2013-01-01T11:00:00Z
8	2013	1	1	557.0	600	-3.0	838.0	846	-8.0	B6	79	N593JB	JFK	MCO	140.0	944	6	0	2013-01-01T11:00:00Z
9	2013	1	1	558.0	600	-2.0	753.0	745	8.0	AA	301	N3ALAA	LGA	ORD	138.0	733	6	0	2013-01-01T11:00:00Z
10	2013	1	1	558.0	600	-2.0	849.0	851	-2.0	B6	49	N793JB	JFK	PBI	149.0	1028	6	0	2013-01-01T11:00:00Z
11	2013	1	1	558.0	600	-2.0	853.0	856	-3.0	B6	71	N657JB	JFK	TPA	158.0	1005	6	0	2013-01-01T11:00:00Z
12	2013	1	1	558.0	600	-2.0	924.0	917	7.0	UA	194	N29129	JFK	LAX	345.0	2475	6	0	2013-01-01T11:00:00Z
13	2013	1	1	558.0	600	-2.0	923.0	937	-14.0	UA	1124	N53441	EWR	SFO	361.0	2565	6	0	2013-01-01T11:00:00Z
14	2013	1	1	559.0	600	-1.0	941.0	910	31.0	AA	707	N708JB	LGA	DFW	257.0	1389	6	0	2013-01-01T11:00:00Z
15	2013	1	1	559.0	559	0.0	702.0	706	-4.0	B6	1806	N708JB	JFK	BOS	44.0	187	5	59	2013-01-01T10:00:00Z
16	2013	1	1	559.0	600	-1.0	854.0	902	-8.0	UA	1187	N76515	EWR	LAS	337.0	2227	6	0	2013-01-01T11:00:00Z
17	2013	1	1	600.0	600	0.0	851.0	858	-7.0	B6	371	N595JB	LGA	FLL	152.0	1076	6	0	2013-01-01T11:00:00Z
18	2013	1	1	600.0	600	0.0	837.0	825	12.0	MQ	4650	N542MQ	LGA	ATL	134.0	762	6	0	2013-01-01T11:00:00Z
19	2013	1	1	601.0	600	1.0	844.0	850	-6.0	B6	343	N644JB	EWR	PBI	147.0	1023	6	0	2013-01-01T11:00:00Z
20	2013	1	1	602.0	610	-8.0	812.0	820	-8.0	DL	1919	N971DL	LGA	MSP	170.0	1020	6	10	2013-01-01T11:00:00Z
21	2013	1	1	602.0	605	-3.0	821.0	805	16.0	MQ	4401	N730MQ	LGA	DTW	105.0	502	6	5	2013-01-01T11:00:00Z
22	2013	1	1	606.0	610	-4.0	858.0	910	-12.0	AA	1895	N633AA	EWR	MIA	152.0	1085	6	10	2013-01-01T11:00:00Z
23	2013	1	1	606.0	610	-4.0	837.0	845	-8.0	DL	1743	N3739P	JFK	ATL	128.0	760	6	10	2013-01-01T11:00:00Z
24	2013	1	1	607.0	607	0.0	858.0	915	-17.0	UA	1077	N53442	EWR	MIA	157.0	1085	6	7	2013-01-01T11:00:00Z
25	2013	1	1	608.0	600	8.0	807.0	735	32.0	MQ	3768	N9EAMQ	EWR	ORD	139.0	719	6	0	2013-01-01T11:00:00Z
26	2013	1	1	611.0	600	11.0	945.0	931	14.0	UA	303	N532UA	JFK	SFO	366.0	2586	6	0	2013-01-01T11:00:00Z
27	2013	1	1	613.0	610	3.0	925.0	921	4.0	B6	135	N635JB	JFK	RSW	175.0	1074	6	10	2013-01-01T11:00:00Z
28	2013	1	1	615.0	615	0.0	1039.0	1100	-21.0	B6	709	N794JB	JFK	SJU	182.0	1598	6	15	2013-01-01T11:00:00Z
29	2013	1	1	615.0	615	0.0	833.0	842	-9.0	DL	575	N326NB	EWR	ATL	120.0	746	6	15	2013-01-01T11:00:00Z

Valor

Un ejemplo ordenado (*tidy*)



Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Unidades: Casos de tuberculosis y población de países por año / Estado epidemiológico anual

Variables: _ _ _ _ _

Valores: _ _ _ _ _


	pais	anio	casos	poblacion
1	Afganistán	1999	745	19987071
2	Afganistán	2000	2666	20595360
3	Brasil	1999	37737	172006362
4	Brasil	2000	80488	174504898
5	China	1999	212258	1272915272
6	China	2000	213766	1280428583

Dataset
WHO

Recordemos...

- Cada variable debe tener su propia columna.
- Cada observación en su propia fila.
- Cada valor en su propia celda.

Un ejemplo ordenado (*tidy*)



Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Unidades: Casos de tuberculosis y población de países por año / Estado epidemiológico anual

Variables: País, año, Casos y Población

Valores: _ _ _ _ _



	país	año	casos	poblacion
1	Afganistán	1999	745	19987071
2	Afganistán	2000	2666	20595360
3	Brasil	1999	37737	172006362
4	Brasil	2000	80488	174504898
5	China	1999	212258	1272915272
6	China	2000	213766	1280428583

Dataset
WHO

Recordemos...

- Cada variable debe tener su propia columna.
- Cada observación en su propia fila.
- Cada valor en su propia celda.

Un ejemplo ordenado (*tidy*)



Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Unidades: Casos de tuberculosis y población de países por año / Estado epidemiológico anual

Variables: País, año, Casos y Población

Valores: Brazil, 1999, 37737, etc.



	país	año	casos	poblacion
1	Afganistán	1999	745	19987071
2	Afganistán	2000	2666	20595360
3	Brasil	1999	37737	172006362
4	Brasil	2000	80488	174504898
5	China	1999	212258	1272915272
6	China	2000	213766	1280428583

Dataset
WHO

Recordemos...

- Cada variable debe tener su propia columna.
- Cada observación en su propia fila.
- Cada valor en su propia celda.

Ejemplos no ordenados



Licenciatura en
Ciencia de Datos
ECYT_UNSAM



	país	anio	tasa
1	Afganistán	1999	745/19987071
2	Afganistán	2000	2666/20595360
3	Brasil	1999	37737/172006362
4	Brasil	2000	80488/174504898
5	China	1999	212258/1272915272
6	China	2000	213766/1280428583

¿Tiene los mismos datos?
¿Por qué no está ordenado?

Tidy, si y solo si...

- Cada variable (País, año, Casos y Población) debe tener su propia columna.
- Cada observación (datos de un país por año) su propia fila.
- Cada valor (Brazil, 1999, 37737, etc.) su propia celda.

Ejemplos no ordenados



Licenciatura en
Ciencia de Datos
ECYT_UNSAM


	país	año	tipo	cuenta
1	Afganistán	1999	casos	745
2	Afganistán	1999	población	19987071
3	Afganistán	2000	casos	2666
4	Afganistán	2000	población	20595360
5	Brasil	1999	casos	37737
6	Brasil	1999	población	172006362
7	Brasil	2000	casos	80488
8	Brasil	2000	población	174504898
9	China	1999	casos	212258
10	China	1999	población	1272915272
11	China	2000	casos	213766
12	China	2000	población	1280428583

¿Tiene los mismos datos?
¿Por qué no está ordenado?

Tidy, si y solo si...

- Cada variable (País, año, Casos y Población) debe tener su propia columna.
- Cada observación (datos de un país por año) su propia fila.
- Cada valor (Brazil, 1999, 37737, etc.) su propia celda.


Ejemplos no ordenados



Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Tipo y nro. de identificación	Legajo	Alumno	Estado	Instancias	Contactos
DNI [REDACTED]	Sin definir	ADAD, LUCAS	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]@gmail.com Teléfono Celular: [REDACTED]
DNI [REDACTED]	Sin definir	AKINYEMI, OLUWATOBI JAMES	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]@gmail.com Teléfono Celular: [REDACTED]
DNI [REDACTED]	Sin definir	ALVAREZ, FEDERICO	Aceptada	Regularidad/Promoción	Email Principal: f[REDACTED]@gmail.com Teléfono Fijo: [REDACTED]
DNI [REDACTED]	CYT-14161	ALVES, FILIPE	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]@gmail.com Teléfono Celular: [REDACTED]
DNI [REDACTED]	Sin definir	ARRUDA, AYLEN SOFIA	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]@gmail.com Teléfono Celular: [REDACTED]
DNI [REDACTED]	Sin definir	BAEZ, EZEQUIEL NICOLÁS	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]@gmail.com Teléfono Celular: [REDACTED]
DNI [REDACTED]	Sin definir	BARON, DANNY	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]a.ar Teléfono Celular: [REDACTED]
DNI [REDACTED]	Sin definir	BLAS, ANDREA DENISE	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]@gmail.com Teléfono Celular: [REDACTED]
DNI [REDACTED]	Sin definir	BRAVO, AGOSTINA	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]@gmail.com Teléfono Celular: [REDACTED]
DNI [REDACTED]	CYT-14193	BRUTTI, LUCA	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]@gmail.com Teléfono Celular: [REDACTED]
DNI [REDACTED]	Sin definir	BUSTAMANTE, FEDERICO ANDRÉS	Aceptada	Regularidad/Promoción	Email Principal: [REDACTED]@gmail.com

Tipos de variables



Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Las **variables** pueden ser de varios **tipos**; un tipo de dato es la “clase” de valores que admite y las operaciones válidas sobre ellos (sumar, comparar, ordenar, etc.).

Todas ellas
pueden ser

Números enteros
(int)

Números
con coma (o *de
punto flotante*)
(dbl)

Fechas
(date / datetime / time)



Cadenas de texto
(chr)

Factores /
Categorías

sched_dep_time	dep_delay	arr_time	sched_arr_time	arr_delay	carrier	flight	tailnum	origin	dest	air_time	distance	hour	minute	time_hour
1030	8.0	1347.0	1340	7.0	AA	19	N328AA	JFK	LAX	344.0	2475	10	30	2013-01-02T15:00:00Z
700	-7.0	855.0	900	-5.0	9E	3769	N820AY	EWR	CVG	104.0	569	7	0	2013-09-16T11:00:00Z
1900	-10.0	2016.0	2014	2.0	US	2160	N953UW	LGA	BOS	34.0	184	19	0	2013-11-05T00:00:00Z
1810	-5.0	1922.0	1945	-23.0	WN	1368	N956WN	LGA	BNA	109.0	764	18	10	2013-09-23T22:00:00Z
600	-9.0	701.0	711	-10.0	EV	4533	N25134	EWR	BUF	48.0	282	6	0	2013-10-09T10:00:00Z
1745	-5.0	2047.0	2110	-23.0	AA	1611	N3FAAA	LGA	MIA	152.0	1096	17	45	2013-08-18T21:00:00Z
1100	171.0	1515.0	1210	185.0	MQ	3230	N532MQ	JFK	DCA	56.0	213	11	0	2013-07-22T15:00:00Z
1035	3.0	1148.0	1159	-11.0	EV	4322	N13123	EWR	MKE	111.0	725	10	35	2013-03-31T14:00:00Z
630	115.0	936.0	749	107.0	EV	4533	N12135	EWR	BUF	47.0	282	6	30	2013-03-28T10:00:00Z
1635	-7.0	1742.0	1810	-28.0	MQ	3695	N527MQ	EWR	ORD	107.0	719	16	35	2013-03-28T20:00:00Z


Visualización de Datos

Data Viz





Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Vuelos desde NYC los días 19 del año 2013 retrasados más de 1 hora




Visualización de Datos

Data Viz





Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Vuelos desde NYC los días 19 del año 2013 retrasados más de 1 hora



Visualización de Datos


Data Viz



Licenciatura en
Ciencia de Datos
ECYT_UNSAM


Presentar
información

Arbolado lineal de especies seleccionadas en CABA




Fuente: Elaboración propia en base a DATA Buenos Aires Ciudad



Datos no estructurados



Licenciatura en
Ciencia de Datos
ECYT_UNSAM





Exhaust
data



FUENTE:

Armado del dataset

Algo un poco más filosófico





Licenciatura en
Ciencia de Datos
ECYT_UNSAM

- A diferencia de otras ciencias como física/química/geología, el objeto de estudio es diseñado: un dataset es **producto de decisiones**.
- Implica abstracciones y elecciones: qué unidades, qué atributos, cómo medir, con qué formato.
- Esas decisiones filtran la realidad: definen inclusiones/exclusiones, umbrales, categorías y limpieza.
- Muchas veces no conocemos a quienes lo construyeron, pero siempre existe un **proceso humano** detrás.
- Es vital tener en cuenta esto al momento de elaborar conclusiones, presentar información o tratar de generalizar.

Bibliografía

Fundamental para el principio





Licenciatura en
Ciencia de Datos
ECYT_UNSAM

En castellano (1ra ed)

<https://es.r4ds.hadley.nz/>

En inglés (2da ed)

<https://r4ds.hadley.nz/>





English only (sorry)



<https://handsondataviz.org/>

Bibliografía


Complementaria



Licenciatura en
Ciencia de Datos
ECYT_UNSAM



...





Licenciatura en
Ciencia de Datos
ECYT_UNSAM

Los datos de hoy

Datos inmobiliarios

La base de Properati



Licenciatura en
Ciencia de Datos
ECYT_UNSAM

- Properati
 - Empresa inmobiliaria fundada en 2012 en Buenos Aires.
 - Opera en varios países de latinoamérica.
 - Comprada por grupos internacionales en 2018 y 2022.
 - Datos abiertos (¿hasta 2022?)
- Conjunto de datos de 2017
 - Incluye un millón de propiedades de Argentina, Uruguay, EEUU y Brasil.
 - Avisos creados desde oct. 2019 a oct. 2020.
 - Información muy rica, con descripción de cada departamento, geolocalizada.



404

No se encontró la página
Prueba con el [buscador](#).

PROPERATI

Datos inmobiliarios

Anuncios publicados en el sitio





Licenciatura en
Ciencia de Datos
ECYT_UNSAM


	id	ad_type	start_date	end_date	created_on	lat	lon	I1	I2	I3	I4	I5	I6	habitaciones	dormitorios
1	ce7dowi+EE4uAwfY/BFTxQ==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.57505	-58.52607	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Barrio Parque General San Martin	NA	NA	1	A
2	vV4L8jgMAcLFzt5+/AP8Jg==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.57505	-58.52607	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Barrio Parque General San Martin	NA	NA	1	A
3	QPuP9ZOdR5DNMMeSeMu3HsA==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.57505	-58.52607	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Barrio Parque General San Martin	NA	NA	1	A
4	DdtKwYf6643k5jOg5afWcA==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.57505	-58.52607	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Barrio Parque General San Martin	NA	NA	1	A
5	tMFDD1bzr96arEPuD5ZM/Q==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.57575	-58.53710	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Barrio Parque General San Martin	NA	NA	1	A
6	iumX+UTM19vbPvExVfVOA==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.57505	-58.52607	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Barrio Parque General San Martin	NA	NA	1	A
7	/iGay2ZbHjlrNO+eeLjuQ==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.57845	-58.54322	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Barrio Parque General San Martin	NA	NA	2	A
8	oZc8RV1xi9ke7E15Er8MKA==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.57505	-58.52607	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Barrio Parque General San Martin	NA	NA	2	A
9	QClocho2eu4BtjqrV2OHZQ==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.54982	-58.57761	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Villa Ballester	NA	NA	3	A
10	Op2ypLYnl5Em1FaY+b5ADg==	Propiedad	2020-05-09	2020-05-20	2020-05-09	-34.54107	-58.53088	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Barrio Parque General San Martin	NA	NA	3	A
11	h72DvzEmwutyq/mVaxKjA==	Propiedad	2019-12-23	9999-12-31	2019-12-23	-34.54988	-58.54934	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Villa Ballester	NA	NA	2	A
12	hJUsrDdKaa/zerpp7vXg0Q==	Propiedad	2019-12-23	2020-01-21	2019-12-23	-34.54091	-58.57434	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Villa Ballester	NA	NA	2	A
13	DASj/H6oSekreiiGvMWXjiQ==	Propiedad	2020-08-17	2020-09-11	2020-08-17	-34.58476	-58.56807	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Villa Libertad	NA	NA	3	A
14	FyGw8vXzahgvnA443k85xQ==	Propiedad	2020-08-17	2020-09-04	2020-08-17	-34.58475	-58.52495	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	NA	NA	NA	6	A
15	BKV871tP6FZkTzK:ltsbg==	Propiedad	2020-04-27	9999-12-31	2020-04-27	NA	NA	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	San Andres	NA	NA	3	A
16	uPkWErNnLC8Cx2oPutik8g==	Propiedad	2020-04-27	9999-12-31	2020-04-27	NA	NA	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	San Andres	NA	NA	1	A
17	DY+Vbw2PwtHbmK5ZcW78FQ==	Propiedad	2020-04-27	9999-12-31	2020-04-27	-34.57379	-58.53482	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	NA	NA	NA	1	A
18	Da1yYH3RjDhw5je+PEaNOg==	Propiedad	2019-12-14	2020-04-02	2019-12-14	-34.57283	-58.57415	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Bilinghurst	NA	NA	3	A
19	6whNfGaM+ug5d3r3mH4Pbw==	Propiedad	2019-12-14	2020-09-17	2019-12-14	-34.58189	-58.53276	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	San Martin	NA	NA	3	A
20	Dnt9gMvFPyC/iH3nadFD+A==	Propiedad	2019-12-14	2019-12-23	2019-12-14	-34.54139	-58.54538	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Villa Ballester	NA	NA	2	A
21	n8/jGLH6nwYr8xoefnTvQ==	Propiedad	2020-04-20	9999-12-31	2020-04-20	-34.56088	-58.55733	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Villa Ballester	NA	NA	3	A
22	OGV4kcIZFo8WqF7RaTnpgCQ==	Propiedad	2020-05-23	2020-06-01	2020-05-23	-34.56587	-58.54299	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	San Andres	NA	NA	3	A
23	Y/C5wC8D6UPtUE2m6PYg==	Propiedad	2019-10-28	2020-02-11	2019-10-28	-34.53958	-58.57281	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Jose Leon Suarez	NA	NA	5	A
24	Yg8YNQjH6VSD5G+R/X/A==	Propiedad	2019-10-28	2020-01-20	2019-10-28	NA	NA	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	NA	NA	NA	2	A
25	L7gNT550g3Q9DTbO6wY4A==	Propiedad	2019-10-28	2020-01-21	2019-10-28	-34.55369	-58.55870	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Villa Ballester	NA	NA	2	A
26	7q2kiNgr7P0+2D5j8pjkow==	Propiedad	2019-10-28	2019-11-04	2019-10-28	-34.54091	-58.57434	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Jose Leon Suarez	NA	NA	2	A
27	H/AaYeMpxTH75luV+A4PLQ==	Propiedad	2019-10-28	2019-11-06	2019-10-28	-34.57900	-58.53801	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	San Martin	NA	NA	3	A
28	Mwbk/jkK4Pk7kakES1FPFQ==	Propiedad	2020-07-16	2020-08-24	2020-07-16	-34.54503	-58.54646	Argentina	Ba.Aa. G.B.A. Zona Norte	General San Martin	Villa Ballester	NA	NA	1	A


Datos inmobiliarios

Geolocalización



Licenciatura en
Ciencia de Datos
ECYT_UNSAM





Licenciatura en
Ciencia de Datos
ECYT_UNSAM

¡Al campus!