

Introducción a la Ciencia de Datos

Guía de trabajos prácticos N°6

Tabla de contenidos

Un ejercicio de Ciencia de Datos	1
Disparadores	2
Pregunta para el <i>dataset</i> Árboles	4
Pregunta para el <i>dataset</i> vuelos	5
Presentación	6

Un ejercicio de Ciencia de Datos

El objetivo de esta guía es utilizar las herramientas vistas hasta ahora para responder una pregunta sobre alguno de los *datasets* que ya conocemos.

Es importante destacar que **NO HAY UNA ÚNICA SOLUCIÓN O CAMINO** para responder cada una de las preguntas. El objetivo es que ganen experiencia en el diseño de un esquema de trabajo que les permita llegar a una respuesta y que se entrenen en los argumentos para convencer que los pasos tomados y los resultados obtenidos son adecuados.

Armen grupos de no más de cinco personas, entre todos van a analizar uno de los *datasets*. Lean la pregunta, piensen y planifiquen los pasos que deberían hacer para encontrar alguna respuesta. Tengan en mente lo visto en clase expositiva, y organicen su análisis paso a paso.

1. En cada paso, pregúntense y respondan:

- ¿qué tenemos que hacer?
 - ¿para qué tenemos que hacerlo?
 - ¿cómo lo haríamos?
 - ¿qué esperamos encontrar?
2. Además, sumen la pregunta ¿qué dificultades potenciales podrían encontrar?
 3. Hagan una tabla con cada paso y la respuesta a cada una de estas preguntas para la presentación.

Disparadores

Algunas ayudas e ideas.

- Ya conocen los *datasets* y los *features* de cada uno, eso ahorra mucho tiempo. Piensen una estrategia para llegar a la respuesta y cuáles de las variables de los datos pueden ser importantes para responder la pregunta y cuáles no.
- ¿Qué esperan encontrar a partir de las variables elegidas?, ¿necesitan buscar, filtrar, agrupar, comparar, buscar relaciones?
- Miren de nuevo las variables descartadas y piensen si alguna les puede servir para entender mejor las cosas del punto anterior.
- De las decisiones que tomaron y las cosas que planificaron ¿Qué datos/análisis podría ser interesante visualizar en un gráfico o tabla? Hagan dibujos a mano alzada de lo que suponen o esperan obtener.

Por Ejemplo: Tenemos que decidir dónde es mejor poner una tipuana tipu de 12 metros sobre Avenida Cabildo. Algunas opciones que podemos pensar son:

“Vamos a plantarlas donde haya otras Tipuanas, así se polinizan entre ellas y florecen más”

¿Qué tenemos que hacer? Filtrar el *dataset* para quedarnos con los árboles de la Av. Cabildo y que sean de la especie Tipuanas.

¿Por qué? Porque estamos intentando encontrar la cuadra o cuabras con más árboles de esta especie.

¿Cómo lo hacemos? Pues así:

```
df_tipu <- df %>% filter(calle_nombre=='Cabildo Av.' &
                        nombre_cientifico=='Tipuana tipu')
```

¿Qué esperamos tener como resultado? El *dataset* filtrado.

Sin embargo, al revisarlo, vemos que no hay árboles de esa especie en Cabildo. Tal vez podríamos haber anticipado esto como uno de las cosas que podrían haber salido mal.

```
count(df_tipu)
```

```
# A tibble: 1 x 1
      n
  <int>
1     0
```

Debemos pensar entonces en otra cosa...

“Vamos a plantarla donde haya menos árboles”

¿Qué tenemos que hacer? Necesitamos ver la densidad de árboles a lo largo de toda la calle.

¿Por qué? Porque en esa cuadra o cuadras podremos plantar los árboles con más facilidad y ayudará a tener cierta uniformidad en la cantidad de árboles por cuadra.

¿Cómo lo haríamos? Usaríamos la columna de calle (para poder filtrar) y la altura/chapa. Con estas variables podríamos hacer un gráfico que muestre la altura de la calle y la cantidad de árboles.

Otra opción podría ser ver la cantidad por cuadra y buscar la cuadra más despoblada.

Más allá del problema de aparentes datos ausentes después del 1200 (¡y tuvimos que tocar varias cosas para evitar errores de ingreso en el *dataset*!) vemos que hay una ligera variación en cantidad de árboles, y que en particular, la cuadra del 1000 tiene pocos ejemplares.

Esta cuadra podría ser nuestra candidata. Pero atención; una revisión en Google Maps nos muestra que es una cuadra muy corta, y por eso tiene pocos ejemplares. Necesitaremos algún criterio adicional...

Como pueden ir viendo, y tal vez adivinando, se trata de un proceso *iterativo*. Esto quiere decir, que van a tener que ir y volver sobre las características del *dataset*, y las ideas que van teniendo, hasta encontrar una forma que lxs convenza que sirve para responder la pregunta.

i Nota**iterativo, va**

3. adj. Mat. Dicho de un procedimiento o de un método: Que llega a un resultado mediante aproximaciones sucesivas.

Fuente: <https://dle.rae.es/iterativo>

La idea es que hagan esta aproximación con un docente, validen el proceso que planearon y cuando hayan concluido **RECIÉN AHÍ** avancen con todo. No se apresuren, ni se pongan ansiosos/as. Esta parte del trabajo es importante y todo el tiempo que pasen pensando en el problema antes de atacarlo es una inversión que les volverá con creces.

Acá van dos preguntas de ejemplo para trabajar en equipos:

Pregunta para el *dataset* Árboles

El Jacarandá es un árbol nativo de la base de las yungas o selvas de montaña, en el noroeste de Argentina. Es considerado uno de los árboles indígenas más bellos del país y fueron incorporados al paisaje porteño por Carlos Thays. Según el último Censo del Arbolado Público Lineal de la Ciudad, en la actualidad hay poco más de 11.000 especímenes. En la mayoría de las fotografías que se utilizan para mostrar escenas típicas de la Ciudad Autónoma de Buenos Aires se observan varios de estos ejemplares.

Sin embargo, una reciente encuesta reveló que hay vecinos y vecinas de la ciudad que no suelen ver esta especie en sus vidas diarias. A partir de este dato, el Ministerio de Ambiente y Espacio Público logró una partida presupuestaria para iniciar una campaña de plantación y posterior mantención de Jacarandás.

En la primera etapa de la campaña se espera poder plantar un total de 20 ejemplares con la proyección de continuar con esta estrategia varios años más.

! Importante

El criterio que quiere tomar el Estado para la ubicación de estos árboles es que no importa la cantidad de peatones que transitan la calle donde se ubiquen los ejemplares, sino que los vecinos que pasen por allí noten lo más posible la presencia del jacarandá.

El gobierno se contactó con ustedes para realizar una consultoría y los ayude a definir a partir de los datos que tienen (`arbolado-publico-lineal-2017-2018.csv`) dónde ubicar estos 20 árboles.

En primer lugar, les piden que piensen con la información disponible cómo definir qué significa que “un vecino note lo más posible la presencia del Jacarandá”. Luego, para determinar la ubicación de los árboles deberán tener en cuenta las siguientes observaciones que realizó el Ministerio:

- Los ejemplares necesitan **que haya por lo menos a 3,5 metros de distancia entre ellos y las casas** para que las ramas que caen tengan menos probabilidades de causar daños.
- No se plantarán nuevos Jacarandás en cuerdas que tengan 15 árboles o más (de cualquier especie, en ambas veredas: par e impar).
- Para hacer los estudios correspondientes a este análisis, puede considerarse que los árboles a plantar van a alcanzar una altura y diámetro similar a la que tienen los Jacarandás en esa misma comuna.

Quiénes los contratan solicitan que les digan las primeras cuerdas en las cuales deberían plantar los Jacarandá.

Fuente de los datos: <https://data.buenosaires.gob.ar/dataset/arbolado-publico-lineal>

Pregunta para el *dataset* vuelos

Corre el año 2014, conseguimos nuestro primer trabajo como científicos de datos en una aerolínea de EEUU. En particular, trabajamos en el departamento que se ocupa de los vuelos que operan desde los tres aeropuertos de Nueva York (JFK: John F. Kennedy; LGA: La Guardia; EWR: Newark). A pocas semanas de arrancar con el trabajo llega una noticia: la empresa consiguió financiamiento para agregar tres aviones a la flota, y quieren que sean utilizados para mejorar la oferta de vuelos desde Nueva York para el 2014, así que nos llaman para ayudar a tomar una decisión acerca de qué rutas hay que reforzar y nos presentan el dataset con los vuelos que hizo la aerolínea en 2013. Por cuestiones administrativas, no se puede ofrecer vuelos a destinos con los que no estén operando.

En una reunión para decidir cómo encarar el problema, se presentaron tres visiones: 1. la de mejorar la seguridad de los vuelos; 2. la de mejorar la experiencia de los viajeros; 3. la comercial (infaltable) de mejorar las ganancias de la compañía.

1. Elijan alguno de estos caminos para plantear la pregunta de manera concreta;

2. **Elijan en qué aerolínea están trabajando**, entre las que volaron más de mil veces en 2013 (ver gráfico abajo);
3. Consideren el tamaño de su aerolínea y la relación con la competencia para dar una respuesta lo más precisa posible.

 Tip

Recién estamos viendo la punta del iceberg del *dataset* de vuelos; si quieren pueden también consultar la tabla **planes** que tiene información sobre cada avión. Ya vamos a trabajar en detalle con datos relacionales, pero por ahora, les dejamos la línea para unir ambas tablas según el número del avión:

Presentación

Al final de la clase vamos a hacer una puesta en común de los diferentes enfoques, lo ideal sería que puedan armar un único documento (.pdf) o una hoja manuscrita. Lo importante es que **expliciten la respuesta a la que llegaron** siguiendo el camino de las preguntas “¿Qué?”, “¿Por qué?” y “¿Cómo?”.

Pueden incluir **esquemas, dibujos a mano alzada** y una **argumentación general de por qué el camino elegido es correcto**. Recuerden que **nos tienen que convencer** de que están dando la mejor solución que se puede dar **con los datos que tienen**, y que ésta se sigue de los datos y análisis. Si necesitan **otras fuentes de datos**, deben aparecer claramente citadas y explicadas en el documento. Finalmente, pueden incluir (opcionalmente) los gráficos que consideren necesarios para mostrar lo que quieran.

Acá también, posiblemente, tengan que ensayar varias explicaciones y líneas de argumentación antes de dar con la correcta. No necesariamente la mejor explicación sea el orden en el que realizaron las tareas.

 Importante

No se frustren, este proceso puede ser duro y lleno de idas y venidas. Charlen con otros equipos, intercambien ideas.

 Tip

- Organicen los resultados obtenidos.
- Decidan qué gráficos o tablas son relevantes para incluir en el proceso

de análisis, es importante sacar conclusiones de cada uno (y que estas se desprendan de los gráficos, claro).

- Expliciten si realizaron alguna suposición o citen la fuente si sacaron un dato de otro lado.
- Es interesante incluir si durante el análisis se encontraron con algo muy diferente de lo que esperaban o si apareció algo digno de mencionar.

Resumen de lo visto en esta Guía:

- El análisis de datos es un proceso **iterativo**: plantear la pregunta, diseñar los pasos y anticipar posibles resultados.
- Estructurar cada paso respondiendo: ¿qué hay que hacer?, ¿para qué?, ¿cómo? y ¿qué se espera encontrar?
- Identificar las variables relevantes del *dataset* y descartar las que no aportan información al problema.
- Reconocer y anticipar las dificultades potenciales de cada paso antes de ejecutarlo.
- Documentar las decisiones, supuestos y fuentes de datos externas utilizadas en el análisis.
- Comunicar los resultados de manera clara, argumentando que las conclusiones se desprenden de los datos.