

Modelado de datos

Introducción al modelo lineal




hasta ahora

- 🌓 Exploración del dataset
- 🌓 Manipulación (orden, filtrado, agrupamiento)
- 🌓 Estudio de distribuciones
- 🌓 Métricas de resumen
- 🌓 Razonamiento con datos
- 🌓 Limpieza de datos

qué es modelar

Queremos describir cómo cambia una variable cuando cambia la otra



hasta ahora, si bien sabemos que ambas variables están asociadas, todavía no podemos usar esta información de forma cuantitativa

$\text{Precio} = f(\text{superficie}, \text{otras_variables})$


para qué modelar



$\text{precio} = f(\text{sup}, \text{otras})$

- Resumir
comprimir muchos datos en pocos números
- Cuantificar
ponerle números a una relación
- Inferir
evaluar si la relación es real o ruido
- Controlar
aislar el efecto de una variable eliminando otras
- Predecir
estimar valores nuevos

para qué modelar



precio = $f(\text{sup}, \text{otras})$


- Resumir
¿Cómo varía el precio con la superficie?
- Cuantificar
Por cada m^2 más, ¿cuánto sube el precio?
- Inferir
¿la relación es significativa o producto del azar?
- Controlar
Lo charlamos más adelante
- Predecir
¿cuánto sale una propiedad de 100m^2 ?

familia de modelos


Expresan un patrón preciso, pero genérico, que se quiere capturar

Ej: lineal, regresión logística, árbol de decisión, red neuronal

Modelos Simples



Modelos Complejos



¿cómo ajustamos las perillas del modelo?

¿cómo ajustamos los parámetros del modelo?

modelo lineal simple

$$Y = a \cdot X + b + \varepsilon$$

modelo lineal simple

variable de respuesta
variable target
variable dependiente


variable predictora
covariable

error — aleatoriedad
otras variables


$$Y = a \cdot X + b + \varepsilon$$

The diagram shows the equation $Y = a \cdot X + b + \varepsilon$ with three variables highlighted in colored circles: Y in a red circle, X in a blue circle, and ε in a green circle. Red lines connect the text 'variable de respuesta', 'variable target', and 'variable dependiente' to the red circle around Y . A blue line connects the text 'variable predictora' and 'covariable' to the blue circle around X . A green line connects the text 'error' and 'aleatoriedad' to the green circle around ε , and another green line connects 'otras variables' to the same green circle.

modelo lineal simple




modelo lineal simple



Para cada valor de X , la correspondiente observación Y consiste en el valor $a.X + b$ más una cantidad ϵ , que puede ser positiva o negativa, y que da cuenta de que la relación entre X e Y no es exactamente lineal, sino que está expuesta a variaciones individuales que hacen que el par observado (X, Y) no caiga exactamente sobre la recta.

recordemos la ecuación de la recta

$$Y = a . X + b$$




recordemos la ecuación de la recta

$$Y = a \cdot X + b$$


pendiente

ordenada
al origen

$$a = \frac{\Delta y}{\Delta x}$$




modelo lineal simple




$$\text{precio} = a \cdot \text{superficie} + b$$

$$y_i = a \cdot x_i + b + \varepsilon_i$$

$$a \cdot 750 \text{ m}^2 + b + \varepsilon$$




supuestos del modelo lineal




Suponemos que cada observación de la variable respuesta proviene de una distribución normal centrada verticalmente en el nivel implicado por el modelo lineal asumido. Asumimos que la varianza de cada distribución normal es la misma, σ^2


ajuste de parámetros



La familia de funciones definida por el modelo contiene una infinidad de posibles curvas para cada combinación de a y b



residuos



residuo = real - predicho

$r_i = \text{precio}_i - \text{predicción}_i$

hay un residuo por cada punto

un toque de matemática

$$\sum_i^N r_i$$

un toque de matemática

$$\sum_i^N r_i$$

$$\sum_i^N r_i^2$$

un toque de matemática

$$\sum_i^N r_i$$

$$\sum_i^N r_i^2$$

$$RMSE = \sqrt{\frac{1}{N} \sum_i^N r_i^2}$$

un toque de matemática

$$RMSE = \sqrt{\frac{1}{N} \sum_i^N r_i^2}$$

$$RMSE = \sqrt{\frac{1}{N} \sum_i^N \{y_i - (a \cdot x_i + b)\}^2}$$

minimizando esta
función encontramos
los valores para a y b

$$RMSE = \sqrt{\frac{1}{N} \sum_i^N \{\text{precio}_i - (a \cdot \text{superficie}_i + b)\}^2}$$

un toque de matemática

minimizar $RMSE = \sqrt{\frac{1}{N} \sum_i^N r_i^2}$



$$\frac{1}{N} \sum_i^N r_i = 0 \quad \sum_i^N r_i = 0$$

Veamos cómo hacer esto en R

`modelo_lineal.R`

análisis del *summary* del modelo

Call:

```
lm(formula = precio ~ sup_total, data = data)
```

fórmula ajustada

Residuals:

Min	1Q	Median	3Q	Max
-399709	-35573	-13155	21920	360242

distribución de los residuos

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	86179.62	2120.11	40.65	<2e-16 ***
sup_total	382.70	13.24	28.92	<2e-16 ***

información
coeficientes

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 64210 on 2171 degrees of freedom
Multiple R-squared: 0.278, Adjusted R-squared: 0.2777
F-statistic: 836.1 on 1 and 2171 DF, p-value: < 2.2e-16

bondad de
ajuste

análisis del *summary* del modelo

estimación del
valor del coeficiente

		Estimate	Std. Error	t value	Pr(> t)
o.o. (b)	(Intercept)	86179.62	2120.11	40.65	<2e-16 ***
pendiente (a)	sup_total	382.70	13.24	28.92	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

a = 382

b = 86.179

precio = 382 USD/m² . sup_total + 86.179 USD

análisis del *summary* del modelo

Resumir

¿Cómo varía el precio con la superficie? **$\text{precio} = 382 \text{ USD/m}^2 \cdot \text{sup_total} + 86.179 \text{ USD}$**

Cuantificar

Por cada m^2 más, ¿cuánto sube el precio? **382 USD/m^2**

Inferir

¿la relación es significativa o producto del azar? **la relación es significativa**

Controlar

Lo charlamos más adelante

Predecir

¿cuánto sale una propiedad de 100m^2 ? **$382 \text{ USD/m}^2 \cdot 100 \text{ m}^2 + 86.179 \text{ USD} = 124.379 \text{ USD}$**

análisis del *summary* del modelo

incertidumbre en la
estimación

		Estimate	Std. Error	t	value	Pr(> t)
0.0. (b)	(Intercept)	86179.62	2120.11	40.65	<2e-16	***
pendiente (a)	sup_total	382.70	13.24	28.92	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$a = 382 \pm 13$$

$$b = 86.179 \pm 2120$$

análisis del *summary* del modelo

estadístico del test de hipótesis
que testea si el coeficiente es $\neq 0$

		Estimate	Std. Error	t value	Pr(> t)
0.0. (b)	(Intercept)	86179.62	2120.11	40.65	<2e-16 ***
pendiente (a)	sup_total	382.70	13.24	28.92	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1					

$$t = \text{estimate} / \text{std. error}$$

análisis del *summary* del modelo

probabilidad de observar un t value tan extremo o más, asumiendo que el coeficiente verdadero es cero

p-value ó p-valor

		Estimate	Std. Error	t value	Pr(> t)
0.0. (b)	(Intercept)	86179.62	2120.11	40.65	<2e-16 ***
pendiente (a)	sup_total	382.70	13.24	28.92	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

si este número es muy chico, significa que el coeficiente es estadísticamente significativo, es decir, que hay evidencia suficiente para decir que es distinto de cero

análisis del *summary* del modelo

Residual standard error: 64210 on 2171 degrees of freedom

Multiple R-squared: 0.278, Adjusted R-squared: 0.2777

F-statistic: 836.1 on 1 and 2171 DF, p-value: $< 2.2e-16$

análisis del *summary* del modelo

Multiple R-squared: 0.278

$$R^2 = \frac{\sum (y_i - \bar{y})^2 - \sum r_i^2}{\sum (y_i - \bar{y})^2}$$

proporción de
variabilidad
explicada

Es la diferencia entre el error en la estimación sin modelo y el error con modelo. Mide cuánto error se logró eliminar al usar la recta en lugar de la media. Es la variabilidad que el modelo capturó.

Es el error total si no usaras ningún modelo. Es la variabilidad total de Y.

El R^2 mide cuánto mejora nuestra predicción de Y al usar la recta de regresión en lugar de ignorar X.

análisis del *summary* del modelo

Residual standard error: 64210 on 2171 degrees of freedom

$$RSE = \sqrt{\frac{1}{N - p} \sum_i^N r_i^2}$$

con p el número de parámetros del modelo (en este caso, p = 2)

N-p : grados de libertad

está en las unidades de la variable target


indica cuánto difieren, en promedio, las predicciones del modelo de los datos

en promedio, este modelo se equivoca en ± 64.210 USD

análisis de los residuos del modelo


gráfico de residuos vs. predicción

modelo correcto




nube de puntos sin estructura alrededor del eje horizontal

modelo incorrecto



los residuos se dispersan cada vez más (o menos) : la varianza del error no es constante




los residuos siguen un patrón sistemático alrededor de cero: hay una estructura que el modelo no captura

el gráfico de residuos suele tener algún tipo de estructura

análisis de los residuos del modelo


gráfico de residuos vs. predicción

modelo correcto




nube de puntos sin estructura alrededor del eje horizontal

modelo incorrecto



los residuos se dispersan cada vez más (o menos) : la varianza del error no es constante





los residuos siguen un patrón sistemático alrededor de cero: hay una estructura que el modelo no captura

el gráfico de residuos suele tener algún tipo de estructura

En la práctica, los gráficos de residuos no son tan claros como estos


análisis de los residuos del modelo

gráfico de residuos vs. predicción



análisis de los residuos del modelo

gráfico de residuos vs. predicción



Heterocedasticidad: la dispersión de los residuos crece con el valor predicho. Las propiedades más caras tienen errores más grandes. Esto sugiere que la varianza del error no es constante.

Una forma de atacar este problema es transformar las variables, por ejemplo, trabajar con $\log(\text{precio})$ en lugar de precio.

modelo lineal múltiple

$$Y = a \cdot X_1 + b \cdot X_2 + c + \varepsilon$$

$$\text{precio} = a \cdot \text{sup_cubierta} + b \cdot \text{sub_fondo} + c$$

Veamos cómo hacer esto en R

`modelo_lineal.R`

análisis del *summary* del modelo

	Estimate	Std. Error	t	value	Pr(> t)
(Intercept)	45656.50	3276.26	13.94	<2e-16	***
sup_total	259.39	14.81	17.51	<2e-16	***
habitaciones	21875.54	1396.65	15.66	<2e-16	***

$$a = 259 \quad b = 21.875 \quad c = 45.656$$

$$\text{precio} = 259 \text{ USD/m}^2 \cdot \text{sup_total} + 21.876 \text{ USD} \cdot \text{habitaciones} + 45.657 \text{ USD}$$

análisis del *summary* del modelo

■ Controlar

¿Por cada m² más, ¿cuánto sube el precio independientemente del número de habitaciones?

259 USD/m²

¿Por cada habitación más, ¿cuánto sube el precio independientemente de la superficie total?

21.875 USD

los tiburones también comen helado

`modelo_lineal.R`

Estas diapositivas fueron elaboradas en base a los apuntes de Regresión Lineal de María Eugenia Szretter Noste (CEECiS, FCEN-UBA)