


Relational Data


Datos Relacionales



El análisis de un cierto problema puede involucrar más de un *dataset* / tabla de datos


Se le llama **datos relacionales** a esas múltiples tablas de datos, ya que sus relaciones, y no solo los conjuntos de datos individuales, son importantes.

Las relaciones siempre se definen sobre un par de tablas



El típico proceso de integración de datos consiste en:

- Extracción: ¿diferentes interfaces?
- Limpieza: ya trabajado en clase (formato de mismos atributos, tratamiento de datos faltantes con mismo criterio).
- Estandarización: evaluar los atributos de la misma forma en todos los datasets.
- Transformación: realizar las transformaciones necesarias para que la nueva tabla de datos sume al análisis de nuestro problema
- Integración**



aerolineas #> # A tibble: 16 × 2 #> aerolinea nombre #> <chr> <chr> #> 1 9E Endeavor Air Inc. #> 2 AA American Airlines Inc. #> 3 AS Alaska Airlines Inc. #> 4 B6 JetBlue Airways #> 5 DL Delta Air Lines Inc. #> 6 EV ExpressJet Airlines Inc.	aviones #> # A tibble: 3,322 × 9 #> codigoCola anio tipo fabricante modelo motores asientos velocidad #> <chr> <int> <chr> <chr> <chr> <int> <int> <int> #> 1 N10156 2004 Ala fija mu... EMBRAER EMB-14... #> 2 N102UW 1998 Ala fija mu... AIRBUS INDU... A320-2... #> 3 N103US 1999 Ala fija mu... AIRBUS INDU... A320-2... #> 4 N104UW 1999 Ala fija mu... AIRBUS INDU... A320-2... #> 5 N10575 2002 Ala fija mu... EMBRAER EMB-14... #> 6 N105UW 1999 Ala fija mu... AIRBUS INDU... A320-2...
clima #> # A tibble: 26,115 × 15 #> origen anio mes dia hora temperatura punto_rocio humedad #> <chr> <int> <int> <int> <int> <dbl> <dbl> <dbl> #> 1 EWR 2013 1 1 1 39.0 26.1 59.4 #> 2 EWR 2013 1 1 2 39.0 27.0 61.6 #> 3 EWR 2013 1 1 3 39.0 28.0 64.4 #> 4 EWR 2013 1 1 4 39.9 28.0 62.2 #> 5 EWR 2013 1 1 5 39.0 28.0 64.4 #> 6 EWR 2013 1 1 6 37.9 28.0 67.2	aeropuertos #> # A tibble: 1,458 × 8 #> codigoAeropuerto nombre latitud longitud altura zona_horaria horario_verano #> <chr> <chr> <dbl> <dbl> <dbl> <dbl> <chr> #> 1 04G Lansdow... 41.1 -80.6 1044 -5 A #> 2 06A Moton F... 32.5 -85.7 264 -6 A #> 3 06C Schaumb... 42.0 -88.1 801 -6 A #> 4 06N Randall... 41.4 -74.4 523 -5 A #> 5 09J Jekyll ... 31.1 -81.4 11 -5 A #> 6 0A9 Elizabe... 36.4 -82.2 1593 -5 A

aeropuertos

codigo_aeropuerto
...

aviones

codigoCola
...

vuelos


anio
mes
dia
hora
vuelo
origen
destino
codigoCola
aerolinea
...

clima

anio
mes
dia
hora
origen
...

aerolineas

aerolinea
nombre



Clave o key: Variable (o conjunto de variables) que identifican **de manera única una observación**

Clave Primaria

Identifica únicamente una observación en su propia tabla.

Por ejemplo, `aviones$codigoCola` es una clave primaria, ya que identifica de manera única cada avión en la tabla `aviones`.

Clave Foránea

Únicamente identifica una observación en otra tabla.

Por ejemplo, `vuelos$codigoCola` es una clave foránea, ya que aparece en la tabla `vuelos`, en la que une cada vuelo con un único avión.

aviones	códigoCola	año	tipo	fabricante	modelo	motores	asientos	velocidad	...	
vuelos	año	mes	día	hora	vuelo	origen	destino	códigoCola	aerolínea	...

Una clave primaria y su correspondiente clave foránea en otra tabla forman una relación.
Las relaciones son típicamente uno-a-muchos.

Chequear siempre que la clave identifique efectivamente de forma única cada observación.

¿Se les ocurre otro ejemplo de variable que en un dataset sea clave primaria y en otro clave foránea?

¿Qué pasa con el dataset vuelos? ¿Cuál es su clave primaria?

aerolínea		airports		aviones		clima		vuelos
aerolínea		código_aeropuerto		códigoCola		origen		año
nombre		nombre		año		año		mes
		lat		tipo		mes		día
		lon		fabricante		día		hora
		alt		modelo		hora		vuelo
		zona_horaria		motores		temperatura		origen
		horario_verano		asientos		punto_rocío		destino
		...		velocidad		humedad		códigoCola
				...		...		aerolínea
								...

En caso de que no exista una variable que identifique únicamente cada observación puede ser útil agregar una: **clave subrogada**

Unión de transformación

Una unión de transformación te permite combinar variables a partir de dos tablas.

Busca coincidencias de observaciones de acuerdo a sus claves y luego copia todas las variables de una tabla en la otra.


Unión interior (*inner join*)

Mantiene las observaciones que aparecen en ambas tablas.

`inner_join(vuelos, aerolíneas, by = "aerolínea")`

`by = c("aerolínea", "año")`

X		Y	
1	x1	1	y1
2	x2	2	y2
3	x3	4	y3



llave	val_x	val_y
1	x1	y1
2	x2	y2

Las filas no coincidentes no se incluyen en el resultado


`by = NULL` usa todas las variables que aparecen en ambas tablas, lo que se conoce como unión natural.

Probemos esto en R Studio


Unión exterior (*outer join*)

Mantiene las observaciones que aparecen en al menos una de las tablas.


left_join(vuelos, aerolíneas, by = "aerolínea")



right_join(vuelos, aerolíneas, by = "aerolínea")




full_join(vuelos, aerolíneas, by = "aerolínea")




Probemos esto en R Studio

Ojo con los duplicados



llave	val_x	val_y
1	x1	y1
2	x2	y2
2	x3	y2
1	x4	y1

Típico cuando queremos agregar información adicional da una relación uno a muchos (ej: vuelos y aerolíneas).



llave	val_x	val_y
1	x1	y1
2	x2	y2
2	x2	y3
2	x3	y2
2	x3	y3
3	x4	y4


Esto es usualmente un error debido a que en ninguna de las tablas las claves identifican de manera única una observación.

Resultado: se obtienen todas las posibles combinaciones


Uniones de filtros (*filter unions*)

Uniones afectando las observaciones en sí, y no a las variables

semijoin(x, y, by = "")




antijoin(x, y, by = "")



Probemos esto en R Studio

Todo esto y mucho más...



Cap. 13