

Introducción a la Ciencia de Datos

Guía de trabajos prácticos N°9

Tabla de contenidos

Introducción	1
Análisis del conjunto de <i>datasets</i>	1
Trabajando con comandos de <i>Relational Data</i>	2
Sigamos practicando con el <i>dataset</i>	3
Ahora un poquito de modelo lineal para no perder la costumbre	4

Introducción

Esta vez nos toca trabajar con datos de `football_data` que van a encontrar en el campus.

Análisis del conjunto de *datasets*

Vamos a trabajar con 7 *datasets* de estadísticas de fútbol y apuestas de las cinco mejores ligas europeas entre los años 2014 y 2020. Los datos fueron tomados de [acá](#).

1. Explore todos los *datasets* para comprender los atributos de cada tabla. La [fuente](#) de los datos les puede resultar muy útil para ello (tengan en cuenta que algunos *datasets* fueron modificados y se quitaron algunos atributos). En [este link](#) y [este otro](#) van a encontrar información sobre qué son las Xstats. Pueden utilizar comandos como `glimpse()` o `colnames()` para este ejercicio.

 Nota

Especial atención a la diferencia entre *shots* (tiros) y *shots on target* (tiros al arco). [Acá](#) hay una explicación.

 Tip

Para importar el *dataset* de *players* (jugadores) van a necesitar agregar el siguiente parámetro al comando `read_csv` para no tener problema con los caracteres especiales:

```
read_csv(ruta_de_acceso,  
         locale = readr::locale(encoding = "latin1"))
```

2. Hagan un esquema a mano o utilizando una Hoja de Cálculo de Google con las variables de cada *dataset* (algo así como hicimos para el *dataset* `vuelos` en la presentación de esta clase).
3. Utilicen el esquema armado para identificar las claves primarias y las claves foráneas (o conjuntos de claves si no fuera suficiente con una sola) en los diferentes *datasets*. Verifiquen que la clave o el conjunto de claves elegidas para cada *dataset* identifiquen de forma única cada observación.

 Tip

Para eso pueden utilizar el comando `count()` con las claves primarias y buscar las entradas con n mayor a uno (ver [Cap. 13.3 de R para Ciencia de Datos](#)).

Respondan: ¿es posible detectar claves primarias en todas las tablas?

4. Piensen cómo podrían conectarse los diferentes *datasets*. Tengan en cuenta que, así como pasaba con los *datasets* de `flights`, hay columnas que refieren a la misma variable pero se llaman diferente.

Trabajando con comandos de *Relational Data*

A partir de este momento es **fundamental** que inviertan tiempo en pensar cuál de todos los *datasets* es el más adecuado para responder la pregunta que les estamos o se están haciendo. Se pueden encontrar las mismas respuestas por diferentes caminos, pero si no lo piensan con detenimiento pueden tomar rumbos mucho más empantanados de lo necesario.

- Encuentren los 10 equipos que más goles metieron en todas las Ligas de Europa. Generen un *data frame* que tenga 10 filas que muestren en una columna el `TeamID` y en otra la cantidad de goles totales.

💡 Tip

Para ello primero deberán identificar el *dataset* que tiene esa información y luego trabajar con él. Para esto último pueden ser de utilidad los comandos `group_by()`, `summarise()`, `slice_max()`, `order()` ó `arrange()` y `head()`. Si no recuerdan cómo funcionan, busquen en la documentación o [GOOGLE IT!](#).

- Ahora agreguen una nueva columna al *data frame* anterior con el nombre del equipo. Para esto van a necesitar los comandos que aprendimos durante la clase expositiva para unir *datasets*.
- Hagan un gráfico de barras que muestre la información del ejercicio anterior, donde cada barra tenga el nombre del equipo correspondiente.
- Repitan los ejercicios 5 a 7 pero en vez de analizar la cantidad de goles totales, analicen los tiros al arco (*shots on target*).

Sigamos practicando con el *dataset*

- Encontremos la Liga que tiene a los equipos con mejor relación tiros - goles.
 - Utilicen el *dataset* `teamstats` y agreguen una columna que indique a qué Liga pertenece cada tiro realizado.

💡 Tip

Para eso van a necesitar crear un *dataset* que tenga sólo las variables `GameID` y `LeagueID` y realizar algún tipo de unión entre esta y la tabla `teamstats`. Chequeen que la unión haya sido correcta: no deberían aparecer duplicados en el *dataset* `teamstats`.

- Armen un *dataset* que indique la cantidad de tiros (*shots*) y de goles (*goals*) **por equipo**, donde además se muestre a qué liga pertenece cada uno.
- Realicen un gráfico de dispersión de la cantidad de goles en función de la cantidad de tiros y coloreen según la Liga. Pueden probar también utilizando el comando `facet_wrap(~Liga)` para separar los gráficos según la Liga.

- Realicen un ajuste lineal con la fórmula `goals ~ shots` para cada Liga y con ello determinen qué Liga tiene la mejor relación *shots-goals* por equipo.

i Nota

Uff... qué laburo esto de tener que filtrar cada Liga para poder hacer estos ajustes.

No se preocupen, ¡la semana que viene vamos a aprender a hacer esto en una sola línea de código!

10. Elijan una de las 5 ligas europeas. Quédense con los 5 jugadores que más goles han metido en esa Liga. Analicen la distribución de tiempos (en minutos) en los cuales estos jugadores realizaron los goles **sin importar en qué club lo hicieron**. Para ello:
 - Consideren que todos los goles realizados son el resultado de tiros al arco (*shot*). Van a poder entonces encontrar todos los goles realizados a partir del atributo *shotResult* del *dataset shots*.
 - Puede serles útil el comando `semi_join()` como se explica en el [Cap. 13.5 de R para Ciencia de Datos](#).
 - Pueden usar `ggridges` para mostrar las 5 distribuciones en un mismo gráfico.

Ahora un poquito de modelo lineal para no perder la costumbre

11. Realicen un gráfico de dispersión (*scatter plot*) entre las variables goles totales y tiros al arco totales (*shots*) para **todos los equipos del *dataset***. Analicen y decidan qué variable pondrían en cada eje. Piensen antes de realizar el gráfico qué tipo de relación esperan encontrar.

Respondan: ¿se observa alguna relación entre la cantidad de tiros al arco y la cantidad de goles convertidos? ¿Es la relación que esperaban?

12. Realicen los siguientes ajustes lineales a la tendencia observada:

- $\text{goals} = w_0 + w_1 \cdot \text{shots}$
- $\text{goals} = w_0 + w_1 \cdot \text{shots} + w_2 \cdot \text{shots}^2$
- $\text{goals} = w_0 + w_1 \cdot \text{shots} + w_2 \cdot \text{shots}^2 + w_3 \cdot \text{shots}^3$

Para cada caso realicen un gráfico donde se vean los puntos y la recta/curva ajustada. Revisando las métricas de cada ajuste y **con los conocimientos que poseen hasta ahora**, decidan cuál es el modelo más adecuado para describir la relación.

 Tip

Notarán que hay veces en las cuales no es necesario agregar una ordenada al origen al ajuste, la cual R agrega por defecto cada vez que definimos un modelo lineal. Para poder excluirla (es decir, tener algo como por ejemplo $\text{goals} = w_1 \cdot \text{shots} + w_2 \cdot \text{shots}^2$) se debe agregar un `-1` al momento de la definición de la fórmula, así:

```
mod <- lm(goals ~ shots + I(shots^2) -1, data = teamstats_goals)
```

Prueben este código con el/los modelo/s que crean necesario.

Resumen de lo visto en esta Guía:

- Concepto de clave primaria y clave foránea para identificar y conectar tablas.
- Verificación de unicidad de claves primarias con `count()`.
- Unión de tablas con `inner_join()`, `left_join()`, `right_join()` y `full_join()`.
- Unión filtrante con `semi_join()` para conservar filas de una tabla que tienen correspondencia en otra.
- Selección del *dataset* y del tipo de unión adecuados según la pregunta a responder.
- Aplicación integrada de `group_by()`, `summarise()`, `arrange()` y `slice_max()` en datos relacionales.
- Ajuste de modelos lineales simples y polinómicos (`I(shots^2)`) sobre datos combinados de múltiples tablas.