

Universidad Nacional de General San Martín
 Escuela de Ciencia y Tecnología
 Campus Miguelete
 Martín de Irigoyen 3100
 San Martín
 Buenos Aires - Argentina
 www.unsam.edu.ar



PROYECTO DE CÁTEDRA		
MATERIA	Introducción a la Ciencia de Datos	
CARRERAS	Lic. en Ciencia de Datos	
MODALIDAD	Bimodal	
SEDE (si es presencial)	Campus Miguelete	
TIPO	Teórico-práctica	
PERÍODO DE VIGENCIA	Segundo cuatrimestre (2024)	
DURACIÓN	Cuatrimestral	
EQUIPO DOCENTE	Profesor/a: Rodrigo F. Díaz JTP: Luis Agustín Nieto, María Sol Espain Ayudantes: Leila Asplanato	
MATERIAS CORRELATIVAS	--	
CARGA HORARIA	Clases Teórico-prácticas: 6h	Total de horas semanales: 6 h Total de horas de la materia: 96 h

MARCO REFERENCIA

Introducción a la Ciencia de Datos tiene como objetivo adentrar a los y las estudiantes de la carrera en el mundo del análisis de datos a través de la práctica. Esta materia inicial busca proveer una visión global del proceso de la ciencia de datos y permitir a quienes cursan experimentar todos los pasos del proceso, aunque sea de manera superficial. Se busca formar un espíritu crítico y una capacidad de análisis de los datos basados en el contacto directo con el objeto de estudio desde la primera clase. Además, se introducen herramientas y técnicas de un nivel básico, pero que son suficientes para la realización de una amplia gama de tareas del científico de datos.

De esta manera, al finalizar la materia, contarán ya con una visión global que irán profundizando a medida que avancen en sus estudios.

OBJETIVOS O PROPÓSITOS

Se espera que quienes participen del curso adquieran las siguientes aptitudes y conocimientos.

Aptitudes

- **Cargar** datos a partir de archivos locales.
- **Juzgar** la calidad de los datos. Ser consciente de las cuestiones de privacidad y ética relacionada con el manejo de datos.
- **Transformar** los datos para presentarlos en formato ordenado ('tidy') para su análisis posterior.
- **Acondicionar** los datos corrigiendo errores, datos faltantes, y otros problemas típicos..
- **Realizar** un análisis exploratorio de datos.
- **Evaluar** y **juzgar** qué tipo de visualizaciones y métricas son relevantes para un conjunto de datos y una tarea/pregunta dados.
- **Acompañar** el análisis con textos descriptivos que permitan entender el contexto y las razones que conducen el análisis.
- **Modelar** los datos utilizando técnicas estadísticas sencillas, como los modelos lineales simples y múltiples.
- **Aplicar** técnicas básicas para lidiar con el problema de inferencia causal, como la incorporación de variables confundidoras.
- **Presentar** los resultados del análisis a sus compañeros de clase públicamente.

Conocimientos

- Conceptos de unidad, variable y observación en relación a un conjunto de datos.
- Diferencia entre datos ordenados y no ordenados; estructurados y no estructurados.
- Métricas básicas para describir un conjunto de datos (media, mediana, desvío estándar, cuartiles, distancia intercuartil, etc.)
- Regulaciones internacionales sobre el manejo de los datos personales.
- Herramientas para realizar exploración de los datos y visualizaciones.
- Funcionamiento y conceptos detrás de diversos tipos de visualizaciones.
- Conceptos básicos relacionados con el modelado de datos: idea de modelo, de parámetros e hiperparámetros; función de pérdida.
- Diferencia entre una relación causal y asociativa entre dos o más variables.

- Entender cómo debe organizarse una presentación que dé cuenta del trabajo realizado y que permita transmitir coherente y eficientemente el proceso y las conclusiones a las que se llegó.

CONTENIDOS

- Introducción práctica al análisis de datos.
- La relación entre los datos y los problemas prácticos.
- Formulación de preguntas relevantes y pasos de resolución de un problema realista de ciencia de datos. Presentación en casos reales.
- Obtención y carga de datos. Formato de almacenamiento de datos (csv, tsv, ascii). Encabezados. Formato de los datos (numérico, string, fechas y otros).
- Técnicas y herramientas de exploración y visualización de los datos.
- Evaluación y corrección de datos. Datos faltantes, datos incorrectos.
- Análisis exploratorio de los datos. Selección, descubrimiento y diseño de *features* relevantes para la resolución de un problema dado.
- Técnicas descriptivas de los datos. Muestras. Valor medio, desvío estándar. Estadísticos. Estimadores. Concepto de correlación y covarianza. Coeficiente de correlación. Coeficiente de Pearson. Coeficiente de Spearman. *Outliers*. Sensibilidad de distintos estimadores a los *outliers*.
- Modelado de los datos. Modelos estadísticos básicos. Parámetros de los modelos.
- Regresión lineal simple. Interpretación. Nociones de ajuste por cuadrados mínimos. Estimadores de los parámetros del modelo lineal. Supuestos del modelo lineal.
- Diagnósticos del ajuste. Evaluación del modelo. Introducción básica a test estadísticos, residuos, QQplots. Residuos. Leverage. Outliers.
- Extensión de los modelos. Modelos aditivos. Regresión lineal múltiple.

ENCUADRE METODOLÓGICO

El proceso de enseñanza de esta primera materia se orienta a la adquisición de aptitudes y habilidades generales, que acompañen a quienes cursan a lo largo de toda la carrera. De esta manera, se hace menos hincapié en la adquisición de conocimientos cerrados sobre los temas desarrollados y más en el desarrollo de un

espíritu analítico que favorezca el desarrollo posterior de las aptitudes necesarias para la ciencia de datos. Al ser una asignatura del primer cuatrimestre de la carrera, no se realizan desarrollos formales de los conceptos de estadística y matemática asociados, sino que se busca despertar una intuición en el manejo de estas ideas y una claridad acerca de su utilidad para el trabajo con datos. Todos los conceptos serán formalizados en asignaturas posteriores.

Para el manejo de los datos, se utiliza el lenguaje R, cuya alta expresividad permite transmitir los conceptos de la materia y que quienes cursan adquieran habilidades de manipulación y modelado de datos sin entrar en los detalles de programación de un lenguaje formal, que serían inadecuados para este momento de la carrera.

Durante las primeras 10 u 11 semanas del cuatrimestre, las clases cuentan con una primera parte expositiva dialogada, en la que se presentan los nuevos conceptos y herramientas a desarrollar durante la clase. Se busca incentivar la participación, presentando situaciones a resolver por parte de los alumnos. Esta parte es mayormente dictada al principio de la clase presencial, pero en algunos casos, según la temática y los tiempos disponibles en cada unidad, se dictará durante las horas de encuentros virtuales sincrónicos. Se sigue con una instancia de trabajo práctico realizado en los laboratorios de computación con una guía escrita, que permite a quienes cursan profundizar progresivamente en el manejo de los conceptos de la clase, siempre a través del manejo y el contacto con los datos. A lo largo de la clase, se realizan puestas en común donde se refuerzan los conceptos que se van trabajando, y se los vincula con la presentación expositiva del principio de la clase o de la clase virtual. En esta instancia se utilizan las experiencias del trabajo práctico. En particular, se hace hincapié en las dificultades encontradas, para motivar una visión crítica del trabajo realizado.

Las últimas clases del cuatrimestre están destinadas al desarrollo del TP final grupal (ver más abajo). Durante estas clases, cada grupo cuenta con un docente guía primario

y uno secundario. Las clases presenciales se utilizan para informar sobre los avances realizados y dificultades encontradas, y se discute entre docentes guías y estudiantes los próximos pasos del trabajo.

Las clases virtuales en las que no se hace una exposición como la descrita arriba se emplean para ahondar en los contenidos de la clase presencial, y para presentar herramientas prácticas de índole técnico. Se espera que las herramientas adquiridas en estas clases se empleen durante las clases presenciales posteriores. Además, durante las horas de cursada virtual se propiciará que quienes cursan presenten sus dudas y las dificultades encontradas para compartir con el resto del curso y recibir el acompañamiento necesario.

Además de las guías detalladas para la realización de los trabajos prácticos en el laboratorio, se pone a disposición una serie de cápsulas (videos asincrónicos) con contenidos técnicos específicos o que presentan nuevas herramientas, para que puedan servir como material de consulta permanente por parte de quienes cursan la materia.

METODOLOGÍA DE EVALUACIÓN

Se utilizan técnicas de evaluación permanente. Además de las interacciones durante la parte expositiva de la clase y la parte práctica, los estudiantes deben realizar **dos trabajos prácticos** para entregar. Estos consisten en varias preguntas de verificación de comprensión, y alguna producción con datos, generalmente un gráfico y un breve texto descriptivo. Durante encuentros posteriores, se realiza una devolución de los trabajos presentados, en formatos que variarán a lo largo del cuatrimestre, para incentivar a quienes cursan a dar y recibir devoluciones críticas y fundadas sobre sus creaciones y la de sus compañeros/as.

La materia cuenta con dos exámenes parciales, en formato presencial, en las semanas 5 y 11 del curso. Se trata en ambos casos mayormente de preguntas de opción múltiple

orientadas a evaluar los contenidos formales de la materia. La aprobar cada parcial es necesario responder correctamente el 60% de las consignas. Por último, se realiza un trabajo final grupal, que consiste en llevar adelante un proyecto de datos de principio a fin, que debe ser presentado frente al resto de la clase a través del uso de diapositivas y otros soportes gráficos. Se da libertad en la elección del tema y de la pregunta a abordar, en la que se trabaja durante las últimas semanas de clases, con la guía cercana de los docentes (ver arriba). Esta instancia tiene un rol clave en la materia, porque permite sintetizar las aptitudes y conocimientos adquiridos, y llevarlos a la práctica. En cada semana, los grupos deben presentar informes de avance con consignas específicas. Estos informes también se utilizan como elemento de evaluación para formar una nota global del desempeño de cada grupo. El TP final cuenta con una nota individual y una nota grupal, que se combinan para dar una nota del trabajo final. Los trabajos son evaluados por el conjunto del equipo docente en base a una rúbrica que se pone a disposición del estudiantado con anterioridad.

Tanto los parciales como el trabajo final cuentan con una instancia recuperatoria, cuya nota reemplaza a la nota de la primera instancia, incluso si ésta es superior. La nota de la cursada se obtiene de una combinación de las notas de las entregas, las notas de los parciales y la del trabajo final. En este cuatrimestre, la fórmula utilizada para obtener la nota de cursada es:

$$\text{nota de la cursada} = 0,05 * \text{nota_entregas} + 0,5 * \text{nota_parciales} + 0,45 * \text{nota_tp},$$

donde la nota de las entregas es un promedio pesado de las dos entregas, y la nota de los parciales es un promedio de las notas de los dos parciales.

Para regularizar la materia, es necesario cumplir con estos requisitos:

1. contar con la presencialidad en un 75 % de las clases de laboratorio.

2. aprobar los dos exámenes parciales, en la instancia inicial o en instancia de recuperación. Como se menciona arriba, esto equivale a responder al menos el 60% de las consignas de manera correcta.
3. aprobar el trabajo práctico final.
4. obtener una nota de cursada igual o superior a 4 (cuatro).

La materia cuenta con la posibilidad de realizar estudios independientes. En ese caso, el criterio de presencialidad (1) no se evalúa. Asimismo, la propuesta cuenta con régimen de promoción, lo que permite aprobar la materia sin la instancia de examen final. Para promocionar la materia, además de las condiciones expuestas arriba, es necesario, en acuerdo con el Reglamento Genereal de Estudiantes de UNSAM (art.28º, inc. a):

- haber obtenido nota 6 (seis) o más en los exámenes parciales.
- obtener una nota de cursada igual o superior a 7 (siete).

PROGRAMA ANALÍTICO

Unidad 1. Los datos. ¿Qué son los datos? Obtención de los datos. Conceptos de variable, valor, unidad y observación. Población y muestra. Representatividad y sesgos de una muestra de datos. Cuestiones de ética y privacidad. Tipos de datos: datos numéricos (enteros y de punto flotantes), cadenas de caracteres, fechas. Variables categóricas.

Bibliografía:

- H.Wickham y G. Grolemund. *R para ciencia de datos*. O'Reilly Media. 2017.

Unidad 2. Vida de un proyecto de datos. El modelo de proceso CRISP-DM (Cross-industry standard process for data mining). Presentación de un problema o necesidad. Contextualización y formulación de la pregunta (business understanding). Obtención y preparación de los datos apropiados. Generación de una visión del resultado / herramienta / producto final. Visualización de los pasos necesarios para llegar a ese objetivo.

Bibliografía:

- J. Kelleher y B. Tierney. *Data Science*. MIT Press. Essential Knowledge series. 2018

Unidad 3. Preparación y limpieza de datos. La necesidad de la preparación de los datos para el análisis. Evaluación de la calidad de los datos. Datos duplicados. Datos faltantes. Técnicas de imputación de datos faltantes. Compleción por valores medios y medianas segmentada y no-segmentada. Datos relacionales. Unión de tablas. Uniones de transformación (del inglés *mutating joins*). Uniones de filtro (*filtering joins*)

Bibliografía:

- H.Wickham y G. Grolemund. *R para ciencia de datos*. O'Reilly Media. 2017.

Unidad 4. Análisis exploratorio de los datos. Visualización de los datos. Gráficos de barras. Gráficos de barras apiladas. Gráficos de dispersión (scatter plots). Concepto de distribución de parámetros. Métricas descriptivas. Media, mediana y moda. Cuantiles. Cuartiles. Desvío estándar y distancia intercuartil. Sensibilidad a los outliers. Histogramas. Polígonos de frecuencia. Gráficos de densidad. Comparación de distribuciones. Gráficos de cajas (box plots) y de violines. Gráficos de densidad apiladas.

Bibliografía:

- H.Wickham y G. Grolemund. *R para ciencia de datos*. O'Reilly Media. 2017.

Unidad 5. Modelado de los datos. Concepto de modelo estadístico de los datos. Utilidad de los modelos como herramientas de inferencia y como técnica de resumen de los datos. Conceptos de parámetros e hiperparámetros. Variables predictoras y variable objetivo. Modelo lineal de regresión, simple y múltiple. Obtención de los parámetros por cuadrados mínimos. Evaluación del modelo ajustado. Coeficiente de determinación. Residuos. Dispersión en los residuos. qq-plots. Palanca y observaciones influyentes.

Bibliografía:

- H.Wickham y G. Grolemund. *R para ciencia de datos*. O'Reilly Media. 2017.

Unidad 6. Elementos de inferencia estadística. Conceptos de inferencia estadística. Interpretación de los resultados de un modelo lineal. Error en los estimadores. Concepto de p-valor y de tests estadísticos. Conceptos de inferencias estadística bayesiana.

Bibliografía:

- H.Wickham y G. Grolemund. *R para ciencia de datos*. O'Reilly Media. 2017.

Unidad 7. Elementos de inferencia causal. Diferencia entre relaciones asociativas y relaciones causales. La importancia de la inferencia causal. La paradoja de Simpson. Variables confundidoras. Variables de control. Variables de control categóricas. Variables de control continuas. Modelos lineales con variables de control. Modelos con términos de interacción.

Bibliografía:

- H.Wickham y G. Grolemund. *R para ciencia de datos*. O'Reilly Media. 2017.

CRONOGRAMA

Semana 1	Introducción a la materia. Estructura de datos. Scatter Plot. Unidad 1
Semana 2	Tratamiento de datos: agrupamiento, filtrado, orden, proporciones y porcentajes. Gráficos de barras. Unidad 3 y 4
Semana 3	Estadística descriptiva: métricas de resumen y boxplot. Unidades 3 y 4
Semana 4	Distribuciones: histogramas, gráficos de densidad y violines. Unidad 4
Semana 5	Introducción a razonamiento con datos. Unidad 2
Semana 6	Ejercicio Ciencia de Datos. Unidad 2
Semana 7	Limpieza de Datos. Unidad 3
Semana 8	Modelado de datos: Introducción a modelo lineal. Unidades 5 y 6
Semana 9	Relational Data. Unidad 3
Semana 10	Modelo Lineal: cofounders, interacción. Unidades 6 y 7
Semana 11	TP Final
Semana 12	TP Final
Semana 13	TP Final
Semana 14	TP Final
Semana 15	TP Final / Presentaciones TP Final
Semana 16	Presentaciones TP Final

BIBLIOGRAFÍA COMPLEMENTARIA

- *Thinking with Data*. M. Shron. O'Reilly Media. 2014.
- *Fundamentals of Data Visualization*. C. O. Wilke. O'Reilly Media. 2019.
- *Hands-On Data Visualization*. J. Dougherty e I. Ilyankou. O'Reilly Media. 2021.